

检索增强生成技术（RAG）在建筑行业的应用

李明明 刘攀 王晴阳 徐倩

（浙江建投数字技术有限公司，杭州 310013）

【摘要】目前，大语言模型已成为社会广泛关注的焦点。然而，由于工程项目的多元性，建筑业对知识检索的需求呈现显著差异化。基于此，本研究依托检索增强生成技术（RAG），提出构建用于建筑领域智能化问答系统的设计方案，通过元数据标注、文档的切分聚合及向量化存储等技术搭建企业专属向量知识库及关键词库，并结合业务逻辑规则实现大语言模型输出内容的“千人千面”精细化管理，能够适配设计、施工和运维等项目多方参建主体以及企业二级单位的差异化需求。此外，问答系统依靠多维度安全防护体系，包括敏感数据过滤、安全等级划分及联网检索隔离机制，有效保障了知识检索过程中的企业隐私信息安全。项目研究成果为降低信息检索成本，推动建筑业向以数据驱动的知识服务模式转型提供了技术支持。

【关键词】建筑业；自然语言处理；检索增强生成；数据标签；联网隔断

【中图分类号】 TU17

【文献标识码】 A

【文章编号】 1674-7461(2026)02-0028-06

【DOI】 10.16670/j.cnki.cn11-5823/tu.2026.02.05

引言

建筑工程项目的完成需要多方主体的参与，涉及广泛的知识面^[1-3]。项目人员在工程建设过程中，难免存在知识漏洞，查阅书籍、试验分析乃至召开专家研讨会已成为解决施工过程中痛难点的常见方法^[4,5]。然而，上述方法在解决问题的效率上存在一定不足^[6]。

如今，人工智能已成为全社会关注的焦点^[7-10]。基于深度学习的大语言模型为高效解决工程问题提供了新的途径。大语言模型是通过分析输入的海量文本数据以学习语言规律的智能系统，能够理解人类语言的含义，并依据需求输出连贯的文本，帮助用户完成答疑等复杂任务^[11-14]。

通过数字化转型以增强市场竞争力已成为建筑企业的刚需。其中，大语言模型在建筑行业的应用已成为关键环节，后续通过AI模型进行设计方案校对、施工计划制定、建筑标准查询等工作将成为行业常态^[15,16]。目前，已有建筑企业通过本地部署DeepSeek实现知识数据库的私人化定制^[17,18]。然而由于建筑项

目的复杂性^[9]，企业对知识检索的需求呈现显著差异化，仅依靠DeepSeek的本地部署仍难以完全满足。需求的多样性对模型的知识库构建提出了特殊挑战。与此同时，建筑项目涉及人员信息、招投标文件等商业敏感数据，联网检索可能伴随信息泄露的风险^[20-22]。

因此，本项目基于检索增强生成技术（Retrieval-Augmented Generation, RAG），利用数据打标、文本切块聚合及向量化存储等技术构建本地知识库及关键词库，并通过引入业务规则，实现大语言模型输出内容的“千人千面”精细化管理。此外，通过设置信息安全等级、关键信息脱敏及联网检索隔断以保证联网检索时的数据安全。本研究能为建筑行业知识服务模式转型提供效率与安全并行的范式参考。

1 检索增强生成技术（RAG）

检索增强生成是一种融合信息检索与生成式AI模型的混合技术框架，旨在通过构建外部知识库以辅助大语言模型生成更准确且符合上下文语境的内容^[23-25]。生成模型在处理用户请求时，首先从本地知识库内筛

【基金项目】 国家重点研发计划（编号：2023YFC3804302）

【第一作者】 李明明（1984-），男，高级工程师，主要研究方向：建筑数字化管理。

【通信作者】 王晴阳（1998-），男，助理工程师，主要研究方向：建筑数字化管理。

选出语义相关的结构化信息，再将此类知识要素作为生成内容的约束条件，最终驱动语言模型输出兼具事实准确性与语境适配性的内容^[26]。此机制对在知识准确性与时效性方面存在严苛要求的医疗、建筑等领域尤为适用^[27]。

检索增强生成技术架构主要包含索引器、检索器和生成器 3 大模块^[27,28]。索引器是检索过程的基础及提升检索性能的关键，它将整理好的文档进行向量化，并存入向量数据库中；作为检索增强生成系统的核心组件，检索器通过语义相似度计算，从多模态异构数据源中实时定位具备高相关性的信息片段；生成器承担答案合成的职能，通过对检索模块输出的高相关性信息进行语义编码，输出同时满足逻辑严谨性和内容相关性的文本。

通过检索增强生成技术形成结果的步骤如图 1 所示。首先通过数据清洗及向量化构建本地向量知识库。当用户提出需求后，系统会将指令转化为向量，并依据文本余弦相似度与向量知识库进行匹配从而检索出相似文档。对相似文档进行相关性排列以优化生成器所接收的信息质量，最终通过生成模型输出满足用户需求的内容^[26,28]。针对建筑企业的检索增强生成技术介入将在下文中详细阐述。




图 1 检索增强生成技术步骤

2 针对建筑企业的检索增强生成框架

2.1 数据打标及脱敏

针对建筑行业多源异构数据特性及数据安全性需求，本研究提出建筑专业化向量数据库构建方法，具体实施流程包含以下核心阶段。首先，收集涉及设计、施工、运维及成本等领域的建筑专业知识及企业二级单位各部门的基本信息；其次，建立元数据标注体系，

对所收集数据的文本添加元数据属性标签^[29]。标注的属性包括业务领域、组织架构、数据来源及生效时间等；最后，助力实现个性化及精准搜索，以《工程质量管理标准化手册》为例，其标注详情如表 1 所示。此外，通过采用构建文档安全分级体系及敏感词库的方法保障数据隐私安全。首先，根据数据的重要性和敏感性，将文档划分为不同的安全级别，并采取相应的访问控制措施，确保只有授权用户能够访问特定级别的数据；其次，构建累积敏感词库，能够对提示词内联系方式及身份证号等敏感信息进行过滤屏蔽，如表 2 所示。

表 1 《工程质量管理标准化手册》文档标签

标签属性	内容
文档名	工程质量管理标准化手册
业务领域	工程质量管理
组织架构	质量管理部门
安全等级	中
数据来源	集团总部
生效时间	2025/04/01

表 2 敏感信息加密

敏感信息类型	内容
手机号	135****7777
身份证	110101*****7272

2.2 内部关键词库构建

针对企业内部多样化知识的高效检索需求，构建领域适配的专用关键词库是实现知识管理智能化的关键工作。通过系统地梳理建筑专业术语（如混凝土强度^[30]、坍落度^[31]、阴阳角^[32]及压实系数^[33]等）、企业组织架构相关术语（如科研开发部、综合办公室及智慧建造中心等）以及产品线专属词汇（如粗骨料、减水剂、水泥、钢筋混凝土预制桩等），建立多层级的标准化术语体系。在进行人机交互时，系统通过实时比对用户提示词与内部关键词库，采用双向最大匹配算法保障核心术语的完整切分，以提升搜索准确性。

2.3 文档切分

建筑业数据存储过程中可通过文本切块技术将复杂文档拆分为语义连贯的独立单元，实现知识粒度的精细化管控^[34]。针对建筑文档多源异构特性，例如设计规范的长篇条款与施工日志的碎片化记录，依据章节标识特征划分文本块，使单个存储单元承载完整的工程语义，既避免传统全文存储导致的检索噪声，又为后续向量化提供精准的语义载体。文档切分的详细步骤如图 2 所示。




图2 文档切分流程

(1) 文档切块。利用章节标识或者“；”等特殊字符对文档进行分块；

(2) 文本切块向量化。文本切块向量化阶段采用 BGE-M3 多语言嵌入模型^[35]。该模型通过自适应领域微调显著提升建筑专业术语的语义表征能力。通过该模型，能够有效提高例如《建筑施工质量通病防治手册》、结构设计计算书等建筑文本的语义捕捉准确率；

(3) 文本切块聚合。利用层次聚类算法^[36]对相似的文本块进行合并，避免因文档切分导致的语义中断。通过文档聚合，避免检索时出现冗余模块，有助于大模型进行语义理解；

(4) 提取文档关键词以及重要实体。基于 TF-IDF 算法构建建筑领域词频特征矩阵^[37,38]，重点捕获“化学灌浆”“含水量”等高频技术词汇，并利用命名实体识别算法^[39,40]提取“人员姓名”“材料名称”等重要实体；

(5) 聚合切块标记添加。基于前序提取的 TF-IDF 关键词与识别实体，采用元数据标注技术建立可检索的语义标签。通过上述机制可显著提升检索相关性。

2.4 答案检索

为解决建筑企业数据安全与知识更新间的矛盾，本研究设计“本地-联网”安全检索双通道系统。当用户发起查询时，系统首先将问题转化为数学向量，并根据用户的权限以及文档的安全等级，匹配用户可以查看的本地文档知识库。针对获取行业最新动态的需求，系统将依据敏感词库对提示词进行信息过滤后联网获取权威数据。

当用户基于历史问题提出全新需求时，为了确保输出内容符合上文语境，系统需要将历史问答过程与全新的提示词进行合并检索，如图3所示。原则上，企业内部文档均不宜参与联网检索。历史答案可能带有本地存储的文件信息，直接利用合并后的文本进行联网搜索依旧存在数据泄露风险，因此采用联网隔断技术进行信息脱敏。检索步骤如图4所示。




图3 联网搜索的敏感信息泄露




图4 联网隔断技术

(1) 第一次检索。系统最终向用户输出结合本地检索及联网检索物料的综合答案。此时系统会伴随生成用户不可见的联网答案，以便第二次联网检索使用；

(2) 第二次联网检索。用户最新提示词只与第一次输出的联网答案合并。在此基础上进行第二次的联

网搜索,并获得网络物料;

(3) 第二次本地检索。输入系统的文本由用户最新提示词与第一次的综合回答合并组成。根据输入文本,系统从本地数据库中搜索相关内容,并结合第二次联网所获取的物料,依据自定义规则,生成最终答案返回至用户。

2.5 文档重要性排序

通过文本相似度指标以及元数据标签,对搜索相关文档进行排序。本研究构建基于内容匹配度、时效性及组织关联性的三重评分体系,实现建筑行业文档的智能化排序。其具体步骤如下:

(1) 内容相关性评分。利用余弦相似度等指标分析文档与查询语句的语义匹配程度,对搜索结果进行0~100分初步评级,匹配度最高的技术文档给予满分;

(2) 时效动态调整。采用线性衰减模型计算时效得分,以当前年度为基准(2025年=100分),每年递减10分(2024年=90分,2023年=80分),确保优先推荐时效性强的文档;

(3) 组织权限适配。根据用户所属部门层级调整权重。用户所在直接责任部门的文档得100分,如设计人员在检索时,知识库内关于设计部门文档的组织关联性分数为100分,其余文档分数按集团、子公司、分公司的架构体系依次递减。

最终将匹配度分数、时效性分数及组织关联性分数相加,根据总分生成最终排序列表。

2.6 大模型检索结果输入

依据文档重要性排序,将本地存储的结构化数据与通过互联网获取的实时动态数据融合后输入至大语言模型,最终生成符合上文语境,并满足用户需求的内容。

3 面向建筑企业的大模型“浙建 AI 助手”应用

浙建数字基于 DeepSeek 本地部署及自主研发,针对建筑企业的使用需求,搭建“浙建 AI 助手”,其用户界面如图 5 所示。作为一款基于大语言模型研发的智能助手,“浙建 AI 助手”具备企业内部资料检索及分析,建筑专业性知识答疑、多语言文本翻译等多种能力,旨在为建筑企业员工提供高效、准确的信息服务。通过检索增强生成技术介入,在确保生成内容真实性的前提下,显著减少模型因依赖训练数据而产生的“幻觉”^[41],最终提升其在准确性、实时性、领域适配性等方面的能力。此外,通过设置特殊规则,满足建筑企业在公司制度及信息安全方面的严格要求。下文将通过人机交互的问答案例,进一步说明“浙建

AI 助手”的优势。



图 5 浙建 AI 助手

(1) 企业内部资料检索及分析

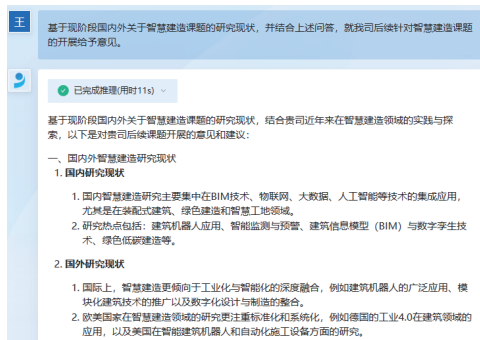
通过构建企业内部专属知识库,实现对企业隐私数据的本地检索,真正贯彻落实“一切工作用数据说话”的管理要求,推动“数据驱动型”决策模式转换。例如,向浙建 AI 助手输入“今年公司盈利状况”“近三年企业针对智慧建造开展的相关科研项目”等提示词,大语言模型通过检索企业内部资料,即可向管理者输出正确的信息,如图 6(a)~(b)所示。此外,依据联网隔断技术,能够实现公司本地信息与互联网实时动态信息的安全结合。例如,在已提出“请提供近三年企业针对智慧建造开展的相关科研项目”问题的基础上,输入提示词“基于现阶段国内外关于智慧建造课题的研究现状,并结合上述问答,就我司后续针对智慧建造课题的开展给予意见”,大语言模型系统即会通过联网检索相关研究现状,并结合我司现阶段的课题进展情况,输出相应的分析及意见,如图 6(c)所示。



(a) 公司盈利状况



(b) 近三年企业针对智慧建造开展的科研项目



(c) 针对企业智慧建造课题的分析及意见

图 6 企业资料检索及分析

(2) 建筑专业性知识检索

通过涉及设计、施工、运维及成本等领域建筑资料的本地知识库，“浙建 AI 助手”在解答建筑专业问题上，同样具备相关优势。如图 7 所示，“浙建 AI 助手”能依据《建筑施工质量通病防治手册》等企业资料解答关于建筑专业的知识，为技术人员提供具备较高可信度的信息指南。



图 7 建筑专业问题解答

4 结论

本研究通过检索增强生成技术（RAG）介入，构建适用于建筑企业的智能化问答系统。依托数据标签、文档分块聚合及向量化存储等技术搭建企业专属知识库，并结合业务逻辑规则实现应答内容的个性化定制，满足企业各二级单位的差异化需求。此外，系统依靠包含安全等级划分、提示词数据脱敏及联网检索隔离技术的多维度安全防护体系，有效保障了知识检索过程的企业内部信息安全。综上所述，研究成果有望为建筑业的数字化转型注入新动力。

参考文献

- [1] 丁超, 苏政, 许城瑜. 基于数字孪生的建筑全生命周期管理平台构建 [J]. 建筑经济, 2023,44(08):73-79.
- [2] 任重翠, 陈才华, 王翠坤, 等. 建设中的超高层建筑高度变化对结构抗震性能的影响 [J]. 建筑结构学报, 2024,45(S2):1-11.

- [3] 吕西林, 蒋欢军. 我国超限高层建筑抗震设计研究与实践进展 [J]. 建筑结构学报, 2025,46(11):127-143+194.
- [4] 徐甘, 黄一如. 修旧如故以存其真——何陋轩保护与修缮 [J]. 建筑学报, 2024,(07):109-118.
- [5] 唐永赫, 史傲, 张景轩, 等. 建筑工程试验检测现状分析及其解决对策 [J]. 中国建筑装饰装修, 2023,(11):133-135.
- [6] 祝雪. 建筑工程造价管理难点与对策研究 [J]. 中国招标, 2024,(12):145-147.
- [7] 魏钰明, 贾开, 曾润喜, 等. DeepSeek 突破效应下的人工智能创新发展与治理变革 [J]. 电子政务, 2025,(03):2-39.
- [8] 潘毅. 人工智能技术在办公建筑改造工程中的应用研究 [J]. 工程抗震与加固改造, 2023,45(03):189.
- [9] 顾海花. 人工智能时代计算机图像识别技术在建筑工程管理中的有效运用 [J]. 建筑科学, 2021,37(11):175.
- [10] 孙龙龙, 王其宽, 施凯, 等. 基于知识图谱的建筑安全领域计算机视觉研究综述 [J]. 安全与环境工程, 2021,28(02):44-49.
- [11] 陈晋音, 席昌坤, 郑海斌, 等. 多模态大语言模型的安全性研究综述 [J]. 计算机科学, 2025,52(07):315-341.
- [12] 张玉铭, 李红岩, 郎许锋, 等. 基于检索增强生成技术的中医药问答大语言模型的构建 [J]. 南京中医药大学学报, 2024,40(12):1375-1382.
- [13] 祝哲, 周文倩, 林婕, 等. 大语言模型技术赋能的应急管理框架 [J]. 指挥与控制学报, 2024,10(06):677-688.
- [14] 王帅, 何文春, 王甫棣, 等. 大语言模型融合知识图谱与向量检索的问答系统 [J]. 科学技术与工程, 2024,24(32):13902-13910.
- [15] 王冰芬, 王国鑫. 大语言模型在 BIM 正向设计领域中的应用探索 [J]. 住宅产业, 2025,(01):80-84.
- [16] 郭茂祖, 张欣欣, 赵玲玲, 等. 结构地震响应预测大语言模型 [J]. 计算机工程与应用, 2025,61(16):132-145.
- [17] 赵阳. 从 DeepSeek 探讨大语言模型在建筑及能源行业的应用趋势和技术方法 [J]. 建筑节能 (中英文), 2025,53(02):1-6.
- [18] 李圣飞, 卢昱杰, 陈晓莹, 等. 基于检索增强生成的建筑工程管理知识问答模型实现 [J]. 科学技术与工程, 2025,25(25):10840-10849.
- [19] 戚爱玲. 工业建筑结构设计的复杂性与安全性 [J]. 现代物业 (中旬刊), 2019,(03):38.
- [20] 杨冲, 佟鑫. 建筑行业数智化转型中的数据安全与隐私保护 [J]. 数字技术与应用, 2025,43(01):64-66.
- [21] 姚银, 彭雪辰. 人工智能背景下的计算机网络安全风险控制 [J]. 信息与电脑, 2024,36(24):142-144.
- [22] 孟慧. 人工智能在信息工程安全领域的保护与隐私安全实践 [J]. 网络安全和信息化, 2024,(12):43-45.
- [23] 朱俊仪, 朱尚明. 利用检索增强生成技术开发本地知识库应用 [J]. 通信学报, 2024,45(S2):242-247.

- [24] 薛晓楠. 结合图检索与上下文排序的检索增强生成技术研究 [J]. 计算机科学, 2025,52(S2):130-133.
- [25] 杜晗, 薛东, 马捷, 等. 基于检索增强生成技术的引信智能检索系统 [J]. 探测与控制学报, 2025,47(05):1-8.
- [26] 刘雪颖, 云静, 李博, 等. 基于大型语言模型的检索增强生成综述 [J]. 计算机工程与应用, 2025,61(13):1-25.
- [27] 张文超, 王玉阳, 郜勇. 检索增强生成的大模型技术在医院 IT 运维中的应用 [J]. 中国卫生信息管理杂志, 2024,21(06):915-919+936.
- [28] 赵静, 汤文玉, 霍钰, 等. 大模型检索增强生成 (RAG) 技术浅析 [J]. 中国信息化, 2024,(10):71-72+70.
- [29] 曾行吉, 罗永明, 廖雪萍, 等. 面向数据集成与共享的元数据设计与应用 [J]. 气象研究与应用, 2024,45(04):108-112.
- [30] 杨聪昆, 周宏宇, 王磊, 等. 既有建筑结构混凝土抗压强度试验研究 [J]. 混凝土, 2025,(12):25-30.
- [31] 邱衍坚, 唐兆龙, 胡峰强, 等. 自密实混凝土坍落度试验数值模拟 [J]. 南昌大学学报 (理科版), 2024,48(05):421-429.
- [32] 王建军. 住宅装配式轻质隔墙板阴阳角处理施工技术研究 [J]. 新城镇科技, 2025,34(04):114-116.
- [33] 唐小东, 陈峰, 张晗辉, 等. 不同压实系数下冻融软土力学特性及孔隙特征研究 [J]. 河南科学, 2024,42(03):355-365.
- [34] 李慧, 刘宇, 张凯翔, 等. 基于统计和语义相似度的智能文档分块方法 [J]. 江苏通信, 2025,41(04):92-95+111.
- [35] 韩明, 曹智轩, 王敬涛, 等. 基于大语言模型的企业碳排放分析与知识问答系统 [J]. 计算机工程与应用, 2025,61(16):370-328.
- [36] 陈斌, 谢文波, 付勋, 等. 基于改进局部密度的可扩展层次聚类算法 [J]. 南京大学学报 (自然科学), 2024,60(03):370-382.
- [37] 宋佳磊, 左兴权, 张修建, 等. 大语言模型评估方法综述 [J]. 宇航计测技术, 2025,45(02):1-30.
- [38] 胡荣笙, 车文刚, 张龙, 等. 融合 TF-IDF 算法和预训练模型的文本数据增强 [J]. 计算机仿真, 2024,41(05):495-500.
- [39] 孙争艳, 陈磊, 魏苏波, 等. 基于边界信息和词汇信息增强的中文命名实体识别 [J]. 南京师范大学学报 (工程技术版), 2024,24(04):79-86.
- [40] 卢昱杰, 申婉玉, 宋广翰, 等. 施工安全非结构化文本命名实体识别方法 [J]. 土木工程与管理学报, 2024,41(06):1-10+47.
- [41] 李能, 于成成, 刘群. 面向生成式文本摘要模型的内在幻觉优化方法 [J]. 重庆邮电大学学报 (自然科学版), 2025,37(05):688-695.

Application of Retrieval-Augmented Generation (RAG) Technology in the Construction Industry

Li Mingming, Liu Pan, Wang Qingyang, Xu Qian

(Zhejiang Construction Investment Digital and Technology Co., Ltd., Hangzhou 310013, China)

Abstract: Currently, large language models have become the focus of society. However, due to the diversity of engineering projects, the construction industry's demand for knowledge retrieval shows significant differences. Based on the above phenomenon, this study leveraged Retrieval-Augmented Generation (RAG) technology to propose a design framework for constructing an intelligent question-and-answer system for the construction field. Through technologies such as metadata tagging, document segmentation and aggregation, and vectorized storage, a dedicated knowledge base and a keyword repository were constructed. By integrating business logic rules, it achieved personalized customization of output content, thereby addressing the heterogeneous requirements of multiple project stakeholders and subsidiary units under group corporations. Besides, the system relied on multi-dimensional security protection system, including sensitive data filtering, safety classification and isolated network retrieval, to effectively ensure information security in the knowledge retrieval process. The research outcomes provide technical support for reducing information retrieval costs and advancing the construction industry's transition toward data-driven knowledge service models.

Keywords: Construction Industry; Natural Language Processing; Retrieval-augmented Generation; Data Tagging; Network Isolation